

Fecha de entrega
21 de Mayo
2026

Tarea 2
Cálculo y Análisis de Componentes
Principales
Dra. Gabriela Berenice Díaz Cortés

14 de Mayo
2026

Instrucciones. Resuelve los ejercicios a mano y muestra todos los pasos de tus cálculos.

Ejercicio 1

(8 puntos)

Análisis de Componentes Principales (PCA) de propiedades de yacimientos

Se han medido tres propiedades de cinco muestras de núcleos de roca de un yacimiento petrolero: porosidad (%), permeabilidad (mD) y viscosidad dinámica del fluido (cP).

Datos de entrada

Muestra	Porosidad (%)	Permeabilidad (mD)	Viscosidad (cP)
1	18	140	150
2	20	180	100
3	22	120	200
4	19	200	80
5	21	160	170

El objetivo es reducir la dimensionalidad de 3 variables a un número menor de componentes principales sin perder demasiada información.

Centrado de datos

(1 pt)

Calcula la media de cada variable:

$$\mu_j = \frac{1}{5} \sum_{i=1}^5 x_{ij}, \quad j = 1, 2, 3.$$

Luego, crea la matriz centrada X_c restando la media de cada variable a todas las observaciones:

$$X_c[i, j] = X[i, j] - \mu_j.$$

Nota: X_c (5 filas $\times$ 3 columnas).

Matriz de covarianza

(1 pt)

La matriz de covarianza muestral está dada por:

$$S = \frac{1}{n-1} X_c^T X_c,$$

donde $n = 5$ es el número de muestras, así que dividimos por $n - 1 = 4$.

Se proporciona la transpuesta:

$$X_c^T = \begin{pmatrix} -2 & 0 & 2 & -1 & 1 \\ -20 & 20 & -40 & 40 & 0 \\ 10 & -40 & 60 & -60 & 30 \end{pmatrix}.$$

Procedimiento (muestra cada cálculo):

- (i) Multiplica $X_c^T \times X_c$. Recuerda que multiplicas $(3 \times 5) \times (5 \times 3)$, resultado es una matriz 3×3 .
- (ii) Divide cada elemento por 4 para obtener $S = \frac{1}{4} X_c^T X_c$.

Los elementos diagonales de S son las varianzas de cada variable. Los elementos fuera de la diagonal miden covarianza entre pares de variables.

Eigenvalores y eigenvectores, direcciones de máxima variabilidad de los datos (2 pts)

Instrucción importante: Calcular los eigenvalores manualmente del polinomio característico de una matriz 3×3 es computacionalmente muy intensivo. Por eso, se proporcionan los eigenvalores y eigenvectores al final. Tu tarea es verificar que tengan sentido.

- (i) Verifica que se cumple la relación fundamental: $Sv_i = \lambda_i v_i$ para **al menos uno** de los eigenvectores. Elige, por ejemplo, el primer eigenvector v_1 y calcula explícitamente Sv_1 (multiplicación matriz-vector). Luego compara con $\lambda_1 v_1$. Deben ser aproximadamente iguales (con pequeños errores de redondeo).
- (ii) Construye la matriz V de dimensión 3×3 cuyas columnas son los tres eigenvectores (en orden de eigenvalor mayor a menor).

Eigenvalores y eigenvectores normalizados (proporcionados):

$$\lambda_1 = 3346.92, \quad \lambda_2 = 104.47, \quad \lambda_3 = 1.11.$$

$$v_1 = \begin{pmatrix} 0.0152 \\ -0.5256 \\ 0.8506 \end{pmatrix}, \quad v_2 = \begin{pmatrix} 0.0772 \\ 0.8487 \\ 0.5231 \end{pmatrix}, \quad v_3 = \begin{pmatrix} -0.9969 \\ 0.0577 \\ 0.0535 \end{pmatrix}.$$

Varianza explicada (1.5 pts)

La fracción de varianza explicada por cada componente esta dada por:

$$p_i = \frac{\lambda_i}{\sum_{j=1}^3 \lambda_j}.$$

- (i) Calcula la suma total: $\sum_{j=1}^3 \lambda_j = \lambda_1 + \lambda_2 + \lambda_3$.
- (ii) Calcula el porcentaje de varianza explicada por cada componente: $p_i \times 100\%$.
- (iii) Calcula la varianza acumulada: $p_1 + p_2$ y $p_1 + p_2 + p_3$.
- (iv) Determina: ¿cuántas componentes necesitas para explicar al menos el 95% de la variabilidad?

Presenta una tabla con columnas: Componente | Eigenvalor | % Varianza | % Acumulada.

Proyección de la primera observación (0.5 pts)

Una **proyección** es un producto punto que mide cuánto de un vector "apunta" en cierta dirección.

Para la **primera observación** (muestra 1), tienes su vector centrado $X_c[1, :] = (X_c[1, 1], X_c[1, 2], X_c[1, 3])$.

La coordenada principal sobre la dirección del eigenvector v_j es:

$$z_{1j} = X_c[1, 1] \cdot v_j[1] + X_c[1, 2] \cdot v_j[2] + X_c[1, 3] \cdot v_j[3].$$

Calcula los tres valores:

- (i) Calcula z_{11} :

$$z_{11} = X_c[1, 1] \cdot v_1[1] + X_c[1, 2] \cdot v_1[2] + X_c[1, 3] \cdot v_1[3].$$

- (ii) Calcula z_{12} :

$$z_{12} = X_c[1, 1] \cdot v_2[1] + X_c[1, 2] \cdot v_2[2] + X_c[1, 3] \cdot v_2[3].$$

- (iii) Calcula z_{13} :

$$z_{13} = X_c[1, 1] \cdot v_3[1] + X_c[1, 2] \cdot v_3[2] + X_c[1, 3] \cdot v_3[3].$$

Presenta el vector completo:

$$z_1 = \begin{pmatrix} z_{11} \\ z_{12} \\ z_{13} \end{pmatrix}.$$

Reconstrucción con diferentes números de componentes

(1.5 pts)

La reconstrucción de una observación usando k componentes se puede obtener como sigue:

$$x^{\text{rec}} = \sum_{j=1}^k z_{1j} \cdot v_j + \mu,$$

donde: - z_{1j} son las coordenadas del Paso 5 (que ya calculaste completamente). - v_j son los eigenvectores del Paso 3. - μ es el vector de medias del Paso 1. - Solo usas los primeros k términos de la suma.

Parte 1: Calcula completamente la reconstrucción con $k = 1$

(i) Con $k = 1$: Usa z_{11} y v_1 .

$$x_1^{\text{rec}} = z_{11} \cdot v_1 + \mu.$$

Muestra el cálculo explícito de las **tres componentes**:

- $x_1^{\text{rec}}[1] = z_{11} \cdot v_1[1] + \mu[1]$
- $x_1^{\text{rec}}[2] = z_{11} \cdot v_1[2] + \mu[2]$
- $x_1^{\text{rec}}[3] = z_{11} \cdot v_1[3] + \mu[3]$

Compara con la observación original $x_1 = (18, 140, 150)$. Calcula el error elemento a elemento: error = $x_1 - x_1^{\text{rec}}$.

Parte 2: Se proporcionan reconstrucciones para $k = 2$ y $k = 3$; calcula los errores

Para $k = 2$ y $k = 3$, se proporcionan los resultados de la reconstrucción. Tu tarea es calcular los errores y completar la tabla de análisis.

Reconstrucciones proporcionadas:

- Con $k = 2$: $x_1^{\text{rec}} = (19.37, 139.92, 149.93)$
- Con $k = 3$: $x_1^{\text{rec}} = (18.00, 140.00, 150.00)$

Tu tarea:

- (i) Calcula el error para $k = 2$.
- (ii) Calcula el error para $k = 3$.
- (iii) Presenta una tabla resumen con:
 - Las tres reconstrucciones ($k=1$ calculada por ti, $k=2$ y $k=3$ dadas).
 - El error para cada k .
 - Observación: ¿cómo disminuye el error conforme aumenta k ?
 - ¿Cuántas componentes son suficientes para un error aceptablemente pequeño?

Esta es la esencia de PCA: puedes representar datos en menos dimensiones sin perder demasiada información. La observación original vive en $\mathbb{R}^3$, pero su variabilidad se concentra en una o dos direcciones. Esto es útil para compresión de datos, visualización en 2D, y eliminación de ruido.

Ejercicio 2

(2 puntos)

Gradiente y matriz Hessiana

Considera la función de pérdida cuadrática:

$$f(w_1, w_2) = \frac{1}{2}(w_1 x_1 + w_2 x_2 - y)^2,$$

con $x_1 = 1$, $x_2 = 2$, $y = 4$. Entonces:

$$f(w_1, w_2) = \frac{1}{2}(w_1 + 2w_2 - 4)^2.$$

- (a) (1 pt) Calcula el gradiente $\nabla f(w_1, w_2)$. Deriva respecto a w_1 y w_2 .
- (b) (1 pt) Calcula la matriz Hessiana H de la función. Luego encuentra sus eigenvalores y eigenvectores.